Cadernos de Scripts - módulo 1

LAPEI-UFG

21/06/2021

Nivelando conhecimentos sobre R

Para começar nosso curso, vamos aplicar operações básicas com o R. Insira os códigos e rode (ctrl + Enter em cima da linha) para ver os resultados.

```
# Operações básicas
5 + 5
```

```
## [1] 10
```

```
10 - 6
```

```
## [1] 4
```

```
10*2
```

```
## [1] 20
```

```
5/2
```

```
## [1] 2.5
```

```
#potência
5**2
```

```
## [1] 25
```

```
# raiz quadrada
sqrt(16)
```

```
## [1] 4
```

```
# veja que os parênteses são usados para estabelecer uma ordem de operações,
# igual aprendemos na matemática
5*(50-45)
```

```
## [1] 25
```

Operações de atribuição

Atribuições são muito importantes! Usamos o "<-" para atribuir o resultado de uma operação a uma variável. É como se eu estivesse falando assim: "R, realize essa operação e guarde em um objeto chamado x"

```
#Atribuições
x <- 5 + 5
y <- 10 - 16
a <- 9
soma <- a + x
nome <- "daniel"
certo <- TRUE
```

Operações básicas

Vamos fazer um programinha para calcular meu índice de massa corpórea (IMC).

```
pesoDaniel <- 79
alturaDaniel <- 1.78
imcDaniel <- pesoDaniel/alturaDaniel**2
```

Agora calcule o IMC de todas as pessoas.

Nome	Peso	Altura
Alice	65	1.60
Gilmar	95	1.78
Cecília	75	1.80
Bianca	77	1.68
Valentina	80	1.72
Augusto	68	1.65

Não existe um jeito mais fácil de calcular?

Vetores

Você até pode calcular o IMC de cada um individualmente.

Mas vou apresentar uma forma de resolver - existem várias formas, usando função, loops. Mas vamos usar um tipo de objeto chamado **vetor**. O vetor é um conjunto unidimensional de objetos de um mesmo tipo (ex.: números, palavras).

Traduzindo... imagina uma tabela de excel formada por várias colunas. Uma das colunas é a idade e está expressa em número. Pronto, um vetor é como se fosse uma coluna com valores de um mesmo tipo.

```
# trabalhando com vetores. Basta colocar um c e abrir parênteses
pesos <- c(65, 95, 75, 77, 80, 68)
alturas <- c(1.60, 1.78, 1.80, 1.68, 1.72, 1.65)
imc <- pesos/alturas**2
imc
```

```
## [1] 25.39062 29.98359 23.14815 27.28175 27.04164 24.97704
```

Consigo arredondar os valores?

Consegue! Só usar a função round.

```
# dica, a função help serve para você pedir uma ajudinha para o R e ver o que a
# função faz
help(round)

round(imc, 2)
```

```
## [1] 25.39 29.98 23.15 27.28 27.04 24.98
```

```
imc <- round(imc, 2) #estou sobrescrevendo um vetor
                     # arredondado sobre ele mesmo
imc
```

```
## [1] 25.39 29.98 23.15 27.28 27.04 24.98
```

Matrizes

As **matrizes** possuem uma estrutura tabular, com linhas e colunas. Porém, semelhante ao vetor, todos os objetos devem ser de um mesmo tipo (ex.: tudo número, tudo caracter).

```
Matriz<-cbind(pesos,alturas,imc)
Matriz
```

```
##      pesos alturas   imc
## [1,]    65    1.60 25.39
## [2,]    95    1.78 29.98
## [3,]    75    1.80 23.15
## [4,]    77    1.68 27.28
## [5,]    80    1.72 27.04
## [6,]    68    1.65 24.98
```

Veja que tem uma aparência de tabela. Mas daqui em diante trabalharemos com outra estrutura chamada **dataframe**. Essa estrutura tem formato tabular e ainda permite que os objetos tenham tipos diferentes, ou seja, posso ter uma coluna numérica, outra no formato data, outra no formato de caracteres e assim por diante.

Existe um tipo de estrutura de dados chamado **lista** muito importante também. Mas entrar nele é assunto para um curso de R intermediário.

```
rownames(Matriz) <- c("Alice","Gilmar","Cecilia","Bianca","Valentina","Augusto")
Matriz
```

```
##           pesos alturas   imc
## Alice        65    1.60 25.39
## Gilmar       95    1.78 29.98
## Cecilia      75    1.80 23.15
## Bianca       77    1.68 27.28
## Valentina    80    1.72 27.04
## Augusto      68    1.65 24.98
```

Introduzindo funções para manipulação de dados

Aqui vamos começar a falar sobre manipulação de dados usando o pacote `dplyr`. É importante instalar os pacotes `dplyr` e `gapminder`, caso já não tenha feito, usando a função `install.packages("dplyr")`, assim como o pacote gapminder, que vai prover a base de dados para o curso.

Inspecionando o dataframe

```
library(gapminder)
library(dplyr)
basePaises <- gapminder

# inspecionando a estrutura da base
str(basePaises)
```

```
## tibble [1,704 x 6] (S3: tbl_df/tbl/data.frame)
##  $ country  : Factor w/ 142 levels "Afghanistan",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ continent: Factor w/ 5 levels "Africa","Americas",..: 3 3 3 3 3 3 3 3 3 3 ...
##  $ year     : int [1:1704] 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997 ...
##  $ lifeExp  : num [1:1704] 28.8 30.3 32 34 36.1 ...
##  $ pop      : int [1:1704] 8425333 9240934 10267083 11537966 13079460 14880372 12881816 13867957 163
##  $ gdpPercap: num [1:1704] 779 821 853 836 740 ...
```

```
# inspecionando as 6 primeiras observações
head(basePaises)
```

```
## # A tibble: 6 x 6
##   country     continent  year lifeExp      pop gdpPercap
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779.
## 2 Afghanistan Asia       1957    30.3  9240934      821.
## 3 Afghanistan Asia       1962    32.0 10267083      853.
## 4 Afghanistan Asia       1967    34.0 11537966      836.
## 5 Afghanistan Asia       1972    36.1 13079460      740.
## 6 Afghanistan Asia       1977    38.4 14880372      786.
```

```
# inspecionando as 10 últimas observações
tail(basePaises, n = 10)
```

```
## # A tibble: 10 x 6
##    country  continent  year lifeExp      pop gdpPercap
##    <fct>    <fct>     <int>   <dbl>    <int>     <dbl>
##  1 Zimbabwe Africa     1962    52.4  4277736      527.
##  2 Zimbabwe Africa     1967    54.0  4995432      570.
##  3 Zimbabwe Africa     1972    55.6  5861135      799.
##  4 Zimbabwe Africa     1977    57.7  6642107      686.
##  5 Zimbabwe Africa     1982    60.4  7636524      789.
##  6 Zimbabwe Africa     1987    62.4  9216418      706.
##  7 Zimbabwe Africa     1992    60.4 10704340      693.
##  8 Zimbabwe Africa     1997    46.8 11404948      792.
##  9 Zimbabwe Africa     2002    40.0 11926563      672.
## 10 Zimbabwe Africa     2007    43.5 12311143      470.
```

```r
# estatísticas descritivas da base
summary(basePaises)
```

```
##         country        continent        year         lifeExp
##  Afghanistan:  12   Africa  :624   Min.   :1952   Min.   :23.60
##  Albania    :  12   Americas:300   1st Qu.:1966   1st Qu.:48.20
##  Algeria    :  12   Asia    :396   Median :1980   Median :60.71
##  Angola     :  12   Europe  :360   Mean   :1980   Mean   :59.47
##  Argentina  :  12   Oceania : 24   3rd Qu.:1993   3rd Qu.:70.85
##  Australia  :  12                  Max.   :2007   Max.   :82.60
##  (Other)    :1632
##       pop              gdpPercap
##  Min.   :6.001e+04   Min.   :   241.2
##  1st Qu.:2.794e+06   1st Qu.:  1202.1
##  Median :7.024e+06   Median :  3531.8
##  Mean   :2.960e+07   Mean   :  7215.3
##  3rd Qu.:1.959e+07   3rd Qu.:  9325.5
##  Max.   :1.319e+09   Max.   :113523.1
##
```

```r
# Acessando uma variável da base
head(basePaises$continent,20)
```

```
##  [1] Asia   Asia   Asia   Asia   Asia   Asia   Asia   Asia   Asia   Asia
## [11] Asia   Asia   Europe Europe Europe Europe Europe Europe Europe Europe
## Levels: Africa Americas Asia Europe Oceania
```

```r
# Acessando elementos únicos
unique(basePaises$year)
```

```
##  [1] 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997 2002 2007
```

```r
# Verificando a média do vetor de expectativa de vida
mean(basePaises$lifeExp)
```

```
## [1] 59.47444
```

```r
# A função glimpse permite dar uma olhadinha nos dados. Parece muito com a
# função str(), mas é do pacote dplyr

glimpse(basePaises)
```

```
## Rows: 1,704
## Columns: 6
## $ country   <fct> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", ~
## $ continent <fct> Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, ~
## $ year      <int> 1952, 1957, 1962, 1967, 1972, 1977, 1982, 1987, 1992, 1997, ~
## $ lifeExp   <dbl> 28.801, 30.332, 31.997, 34.020, 36.088, 38.438, 39.854, 40.8~
## $ pop       <int> 8425333, 9240934, 10267083, 11537966, 13079460, 14880372, 12~
## $ gdpPercap <dbl> 779.4453, 820.8530, 853.1007, 836.1971, 739.9811, 786.1134, ~
```

Abrindo um parêntese

Veja que o glimpse mostra o tipo das variáveis (int, fct, dbl). Existem vários tipos de variáveis no R e compreendê-los é importante, pois determinam possíveis visualizações e técnicas de análise. Apresentei três tipos importantes:

- dbl (double) - valores numéricos e contínuos ("quebrados")
- int (integer) - valores numéricos discretos ("inteiros")
- fct (factor) - uma palavra.

Se alguém a série Stranger Things, da Netflix, vai lembrar o nome dessa menininha: Eleven. Nesse caso, Eleven é um nome, portanto, representaria um factor.

11 (int)

11.05 (dbl)

2011-01-11 (date)

"11"
(fct)

Função filter

Função para filtrar observações de uma base conforme algumas condições. Nesse caso, países cujo continente corresponde à Ásia.

```
basePaises %>%
  filter(continent == "Asia")
```

```
## # A tibble: 396 x 6
##    country     continent  year lifeExp      pop gdpPercap
##    <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
##  1 Afghanistan Asia       1952    28.8  8425333      779.
##  2 Afghanistan Asia       1957    30.3  9240934      821.
##  3 Afghanistan Asia       1962    32.0 10267083      853.
##  4 Afghanistan Asia       1967    34.0 11537966      836.
##  5 Afghanistan Asia       1972    36.1 13079460      740.
```

```
##  6 Afghanistan Asia       1977    38.4 14880372      786.
##  7 Afghanistan Asia       1982    39.9 12881816      978.
##  8 Afghanistan Asia       1987    40.8 13867957      852.
##  9 Afghanistan Asia       1992    41.7 16317921      649.
## 10 Afghanistan Asia       1997    41.8 22227415      635.
## # ... with 386 more rows
```

```
basePaises %>%
  filter(continent == "Americas" & year>1990)
```

```
## # A tibble: 100 x 6
##    country   continent  year lifeExp       pop gdpPercap
##    <fct>     <fct>     <int>   <dbl>     <int>     <dbl>
##  1 Argentina Americas   1992    71.9  33958947     9308.
##  2 Argentina Americas   1997    73.3  36203463    10967.
##  3 Argentina Americas   2002    74.3  38331121     8798.
##  4 Argentina Americas   2007    75.3  40301927    12779.
##  5 Bolivia   Americas   1992    60.0   6893451     2962.
##  6 Bolivia   Americas   1997    62.0   7693188     3326.
##  7 Bolivia   Americas   2002    63.9   8445134     3413.
##  8 Bolivia   Americas   2007    65.6   9119152     3822.
##  9 Brazil    Americas   1992    67.1 155975974     6950.
## 10 Brazil    Americas   1997    69.4 168546719     7958.
## # ... with 90 more rows
```

Nesse caso, precisamos de todas observações, com exceção do continente Oceania. Veja como fica:

```
# != diferente
basePaises %>%
  filter(continent != "Oceania")
```

```
## # A tibble: 1,680 x 6
##    country     continent  year lifeExp      pop gdpPercap
##    <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
##  1 Afghanistan Asia       1952    28.8  8425333      779.
##  2 Afghanistan Asia       1957    30.3  9240934      821.
##  3 Afghanistan Asia       1962    32.0 10267083      853.
##  4 Afghanistan Asia       1967    34.0 11537966      836.
##  5 Afghanistan Asia       1972    36.1 13079460      740.
##  6 Afghanistan Asia       1977    38.4 14880372      786.
##  7 Afghanistan Asia       1982    39.9 12881816      978.
##  8 Afghanistan Asia       1987    40.8 13867957      852.
##  9 Afghanistan Asia       1992    41.7 16317921      649.
## 10 Afghanistan Asia       1997    41.8 22227415      635.
## # ... with 1,670 more rows
```

```
# Você pode armazenar sua consulta em outro objeto
baseAsia <- basePaises %>%
  filter(continent == "Asia")
```

Função select

A função select é muito útil para você selecionar apenas as variáveis que precisa trabalhar. O PSED (base que usaremos no módulo 3) tem mais de 8000 colunas. É prudente usar a função select para separar apenas o que você precisa depois que tiver estudado os dados.

```
basePaises %>%
  select(year,country,gdpPercap)
```

```
## # A tibble: 1,704 x 3
##     year country     gdpPercap
##    <int> <fct>           <dbl>
##  1  1952 Afghanistan      779.
##  2  1957 Afghanistan      821.
##  3  1962 Afghanistan      853.
##  4  1967 Afghanistan      836.
##  5  1972 Afghanistan      740.
##  6  1977 Afghanistan      786.
##  7  1982 Afghanistan      978.
##  8  1987 Afghanistan      852.
##  9  1992 Afghanistan      649.
## 10  1997 Afghanistan      635.
## # ... with 1,694 more rows
```

Quando usamos o - pegamos qualquer variável menos aquela de interesse, nesse caso lifeExp.

```
basePaises %>%
  select(-lifeExp)
```

```
## # A tibble: 1,704 x 5
##    country     continent  year      pop gdpPercap
##    <fct>       <fct>     <int>    <int>     <dbl>
##  1 Afghanistan Asia       1952  8425333      779.
##  2 Afghanistan Asia       1957  9240934      821.
##  3 Afghanistan Asia       1962 10267083      853.
##  4 Afghanistan Asia       1967 11537966      836.
##  5 Afghanistan Asia       1972 13079460      740.
##  6 Afghanistan Asia       1977 14880372      786.
##  7 Afghanistan Asia       1982 12881816      978.
##  8 Afghanistan Asia       1987 13867957      852.
##  9 Afghanistan Asia       1992 16317921      649.
## 10 Afghanistan Asia       1997 22227415      635.
## # ... with 1,694 more rows
```

Função select + filter

Olha que legal, as funções conversam entre si! Então eu posso fazer dois procedimentos - filtrar e depois selecionar - em um só conjunto de comandos.

```
basePaises %>%
  filter(continent == "Americas" & year>1990) %>%
  select(year,country,gdpPercap)
```

```
## # A tibble: 100 x 3
##     year country   gdpPercap
##    <int> <fct>         <dbl>
##  1  1992 Argentina     9308.
##  2  1997 Argentina    10967.
##  3  2002 Argentina     8798.
##  4  2007 Argentina    12779.
##  5  1992 Bolivia       2962.
##  6  1997 Bolivia       3326.
##  7  2002 Bolivia       3413.
##  8  2007 Bolivia       3822.
##  9  1992 Brazil        6950.
## 10  1997 Brazil        7958.
## # ... with 90 more rows
```

Função mutate

A função mutate serve para criar uma nova variável. Nesse primeiro exemplo, criei uma variável chamada GDP (PIB), que é resultado da multiplicação entre as variáveis gdpPercap (PIB per capita) e pop (população).

```
basePaises <- basePaises %>%
  mutate(GDP = gdpPercap * pop)

basePorte <- basePaises %>%
  filter(year == 1992) %>%
  mutate(porte = if_else(pop>median(pop),"G","P"))

head(basePorte)
```

```
## # A tibble: 6 x 8
##   country     continent  year lifeExp      pop gdpPercap           GDP porte
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>         <dbl> <chr>
## 1 Afghanistan Asia       1992    41.7 16317921      649.  10595901589. G
## 2 Albania     Europe     1992    71.6  3326498     2497.   8307722183. P
## 3 Algeria     Africa     1992    67.7 26298373     5023. 132102425043. G
## 4 Angola      Africa     1992    40.6  8735988     2628.  22956828370. G
## 5 Argentina   Americas   1992    71.9 33958947     9308. 316104097627. G
## 6 Australia   Oceania    1992    77.6 17481977    23425. 409511234952. G
```

Funções group_by e summarize

A função group_by geralmente é aplicada associada a outra função, nesse caso, vamos usar associada ao summarize.

```
basePaises %>%
  group_by(country) %>%
  summarize(meanLE=mean(lifeExp),meanPop=mean(pop),meanGpc=mean(gdpPercap))
```

```
## # A tibble: 142 x 4
##    country     meanLE   meanPop meanGpc
```

```
##    <fct>        <dbl>     <dbl>   <dbl>
##  1 Afghanistan   37.5 15823715.    803.
##  2 Albania       68.4  2580249.   3255.
##  3 Algeria       59.0 19875406.   4426.
##  4 Angola        37.9  7309390.   3607.
##  5 Argentina     69.1 28602240.   8956.
##  6 Australia     74.7 14649312.  19981.
##  7 Austria       73.1  7583298.  20412.
##  8 Bahrain       65.6   373913.  18078.
##  9 Bangladesh    49.8 90755395.    818.
## 10 Belgium       73.6  9725119.  19901.
## # ... with 132 more rows
```

Veja como ela funciona: vamos agrupar todas as observações cuja variável *country* for a mesma e, em sequência, aplicar um cálculo de média sobre o agrupamento.

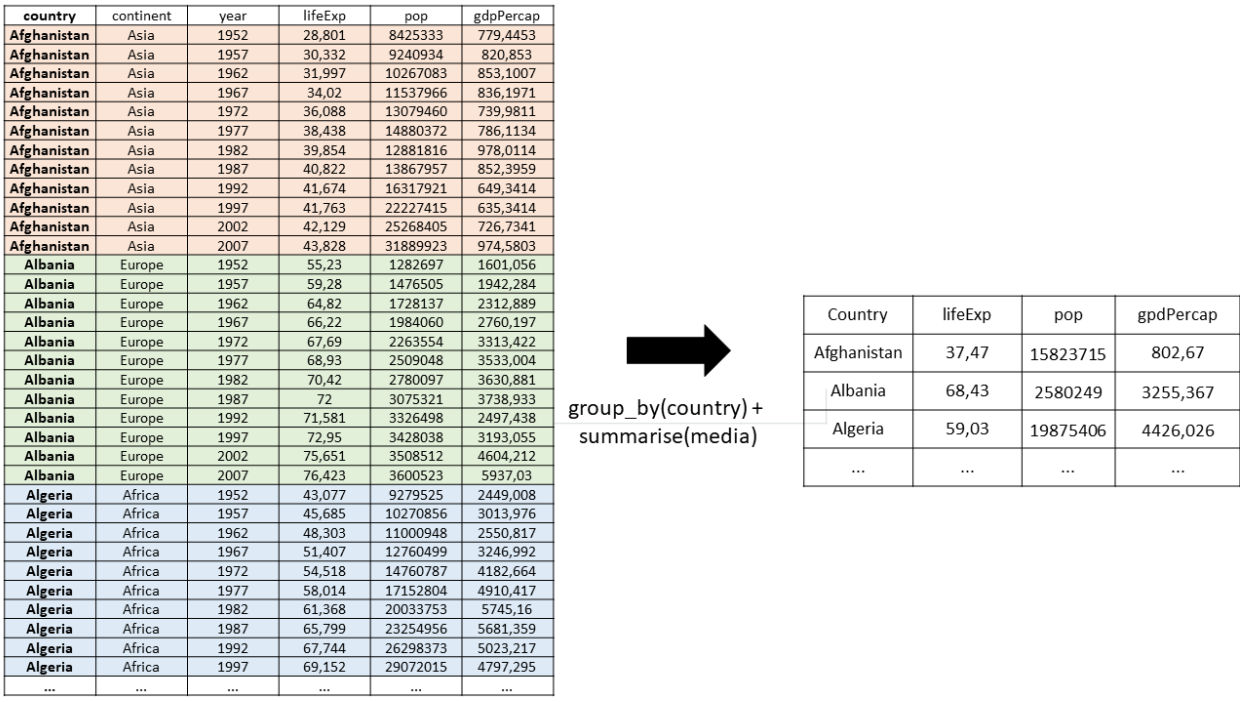

country	continent	year	lifeExp	pop	gdpPercap
Afghanistan	Asia	1952	28,801	8425333	779,4453
Afghanistan	Asia	1957	30,332	9240934	820,853
Afghanistan	Asia	1962	31,997	10267083	853,1007
Afghanistan	Asia	1967	34,02	11537966	836,1971
Afghanistan	Asia	1972	36,088	13079460	739,9811
Afghanistan	Asia	1977	38,438	14880372	786,1134
Afghanistan	Asia	1982	39,854	12881816	978,0114
Afghanistan	Asia	1987	40,822	13867957	852,3959
Afghanistan	Asia	1992	41,674	16317921	649,3414
Afghanistan	Asia	1997	41,763	22227415	635,3414
Afghanistan	Asia	2002	42,129	25268405	726,7341
Afghanistan	Asia	2007	43,828	31889923	974,5803
Albania	Europe	1952	55,23	1282697	1601,056
Albania	Europe	1957	59,28	1476505	1942,284
Albania	Europe	1962	64,82	1728137	2312,889
Albania	Europe	1967	66,22	1984060	2760,197
Albania	Europe	1972	67,69	2263554	3313,422
Albania	Europe	1977	68,93	2509048	3533,004
Albania	Europe	1982	70,42	2780097	3630,881
Albania	Europe	1987	72	3075321	3738,933
Albania	Europe	1992	71,581	3326498	2497,438
Albania	Europe	1997	72,95	3428038	3193,055
Albania	Europe	2002	75,651	3508512	4604,212
Albania	Europe	2007	76,423	3600523	5937,03
Algeria	Africa	1952	43,077	9279525	2449,008
Algeria	Africa	1957	45,685	10270856	3013,976
Algeria	Africa	1962	48,303	11000948	2550,817
Algeria	Africa	1967	51,407	12760499	3246,992
Algeria	Africa	1972	54,518	14760787	4182,664
Algeria	Africa	1977	58,014	17152804	4910,417
Algeria	Africa	1982	61,368	20033753	5745,16
Algeria	Africa	1987	65,799	23254956	5681,359
Algeria	Africa	1992	67,744	26298373	5023,217
Algeria	Africa	1997	69,152	29072015	4797,295
...	...	...	...	...	...

Country	lifeExp	pop	gpdPercap
Afghanistan	37,47	15823715	802,67
Albania	68,43	2580249	3255,367
Algeria	59,03	19875406	4426,026
...	...	...	...

Veja que posso agrupar usando mais de uma variável. Nesse caso, agrupamos todos as observações iguais de continente e ano.

```
basePaises %>%
  group_by(continent,year) %>%
  summarize(meanLE=mean(lifeExp),meanPop=mean(pop),meanGpc=mean(gdpPercap))
```

```
## `summarise()` has grouped output by 'continent'. You can override using the `.groups` argument.
```

```
## # A tibble: 60 x 5
## # Groups:   continent [5]
##    continent  year meanLE   meanPop meanGpc
##    <fct>     <int>  <dbl>     <dbl>   <dbl>
```

```
##  1 Africa     1952   39.1  4570010.   1253.
##  2 Africa     1957   41.3  5093033.   1385.
##  3 Africa     1962   43.3  5702247.   1598.
##  4 Africa     1967   45.3  6447875.   2050.
##  5 Africa     1972   47.5  7305376.   2340.
##  6 Africa     1977   49.6  8328097.   2586.
##  7 Africa     1982   51.6  9602857.   2482.
##  8 Africa     1987   53.3 11054502.   2283.
##  9 Africa     1992   53.6 12674645.   2282.
## 10 Africa     1997   53.6 14304480.   2379.
## # ... with 50 more rows
```

Funções top_n e arrange

A função top_n serve para selecionar os n maiores valores que desejar. Já a arrange permite ordenar em ordem descendente ou ascedente (padrão).

```
basePaises %>%
  filter(year == 2007) %>%
  top_n(5,pop) %>%
  arrange(desc(pop))
```

```
## # A tibble: 5 x 7
##   country       continent  year lifeExp        pop gdpPercap     GDP
##   <fct>         <fct>     <int>   <dbl>      <int>     <dbl>   <dbl>
## 1 China         Asia       2007    73.0 1318683096     4959. 6.54e12
## 2 India         Asia       2007    64.7 1110396331     2452. 2.72e12
## 3 United States Americas   2007    78.2  301139947    42952. 1.29e13
## 4 Indonesia     Asia       2007    70.6  223547000     3541. 7.92e11
## 5 Brazil        Americas   2007    72.4  190010647     9066. 1.72e12
```

As próximas funções de manipulação são os joins, que servem para juntar duas bases. São funções importantíssimas. Vamos falar somente sobre dois tipos de joins (left_join e inner_join). Existem outros, mas esses são os que mais usamos no cotidiano. Para isso, vamos usar duas bases: o Índice de Cidades Empreendedoras (ICE), desenvolvido pela ENAP e Endeavor, e a base MUNIC do IBGE.

Base ICE

Fonte: Índice de Cidades empreendedoras

Base MUNIC

Fonte: MUNIC

Baixando as bases direto do meu github

```
munic <- read.csv("https://raw.githubusercontent.com/danielppagotto/R_empreendedorismo1/main/arquivos%2
```

```
ice <- read.csv("https://raw.githubusercontent.com/danielppagotto/R_empreendedorismo1/main/arquivos%20d
```

Inspecionando as bases

```
glimpse(munic)
```

```
## Rows: 195
## Columns: 9
## $ cod_cidade      <int> 1100155, 1100189, 1100205, 1100254, 1100262, 1200385, ~
## $ reducao_iptu    <chr> "Não", "Sim", "Não", "Não", "Sim", "Sim", "Não", "Não"~
## $ isencao_iptu    <chr> "Sim", "Sim", "Não", "Não", "Sim", "Não", "Não", "Sim"~
## $ reducao_issqn   <chr> "Não", "Não", "Sim", "Não", "Não", "Não", "Não", "Não"~
## $ isencao_issqn   <chr> "Não", "Não", "Não", "Não", "Não", "Não", "Sim", "Não"~
## $ isencao_taxas   <chr> "Não", "Não", "Não", "Não", "Sim", "Sim", "Não", "Não"~
## $ cessao_terrenos <chr> "Sim", "Sim", "Sim", "Não", "Não", "Não", "Não", "Não"~
## $ doacao_terrenos <chr> "Não", "Sim", "Não", "Não", "Sim", "Não", "Não", "Não"~
## $ outros          <chr> "Não", "Não", "Não", "Sim", "Não", "Não", "Não", "Não"~
```

```
glimpse(ice)
```

```
## Rows: 100
## Columns: 11
## $ cidade                <chr> "São Paulo", "Florianópolis", "Osasco", "Vitória~
## $ UF                    <chr> "SP", "SC", "SP", "ES", "DF", "SP", "SP", "SP", ~
## $ cod_ibge              <int> 3550308, 4205407, 3534401, 3205309, 5300108, 354~
## $ ICE                   <dbl> 9.51, 8.12, 7.94, 7.91, 7.58, 7.54, 7.52, 7.46, ~
## $ ambiente_regulatorio  <dbl> 7.97, 6.60, 7.01, 8.90, 4.14, 7.14, 6.63, 6.39, ~
## $ infraestrutura        <dbl> 9.76, 7.15, 6.93, 5.65, 7.35, 6.71, 8.13, 7.48, ~
## $ mercado               <dbl> 7.70, 6.19, 7.55, 6.20, 8.30, 8.13, 7.18, 8.64, ~
## $ acesso_capital        <dbl> 11.33, 8.43, 10.06, 7.32, 6.82, 5.74, 6.11, 6.04~
## $ inovacao              <dbl> 7.22, 8.52, 6.27, 7.26, 6.39, 7.56, 7.67, 6.52, ~
## $ capital_humano        <dbl> 5.82, 8.88, 5.94, 8.05, 6.56, 6.98, 6.40, 7.31, ~
## $ cultura_empreendedora <dbl> 5.54, 5.26, 5.96, 4.33, 3.95, 5.95, 5.90, 6.46, ~
```

Vamos juntar as bases por meio das colunsa cod_cidade e cod_ibge.

Um ponto **muito importante**: ambas variáveis devem ser do mesmo tipo. No caso, ambas estão como `int`. Caso uma fosse factor e a outra `int`, o join geraria uma mensagem de erro.

Vamos supor que o cod_ibge da base ice estive em formato fct (factor, lembra da Eleven do Stranger Things). Para transformá-lo para o formato int seria necessário aplicar o seguinte comando.

```
ice$cod_ibge <- as.integer(ice$cod_ibge)
```

inner_join

Cidade	UF	cod_ibge	ICE	...
São Paulo	SP	3550308	9.51	...
Florianópolis	SC	4205407	8.12	...
Osasco	SP	3534401	7.94	...
...	...	...	...	...

cod_cidade	reducao_iptu	isencao_iptu	...
1100155	Não	Sim	...
1100189	Sim	Sim	...
1100205	Não	Não	...
...	...	...	...

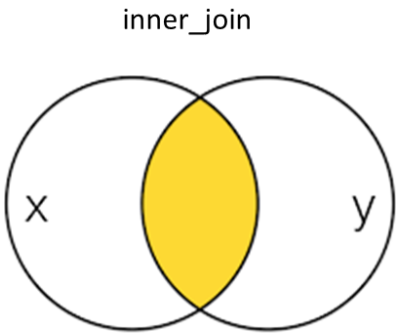


```
inner <- munic %>%
  inner_join(ice, by = c("cod_cidade"="cod_ibge"))
```

left_join

Cidade	UF	cod_ibge	ICE	...
São Paulo	SP	3550308	9.51	...
Florianópolis	SC	4205407	8.12	...
Osasco	SP	3534401	7.94	...
...	...	...	...	...

cod_cidade	reducao_iptu	isencao_iptu	...
1100155	Não	Sim	...
1100189	Sim	Sim	...
1100205	Não	Não	...
...	...	...	...

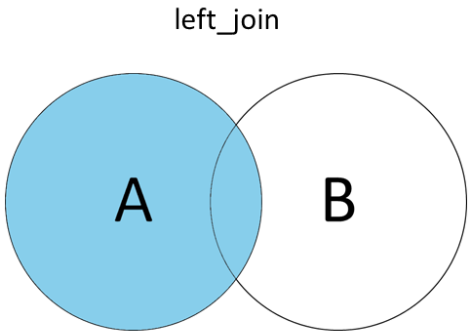

```
left <- munic %>%
  left_join(ice, by = c("cod_cidade"="cod_ibge"))
```

Introduzindo funções para visualização de dados

Dica de leitura

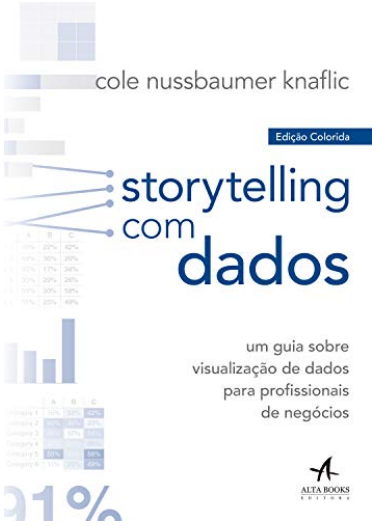

Preparando nosso ambiente

Antes de começar, vamos chamar alguns pacotes e preparar uma base que usaremos! Caso ainda não tenha algum dos pacotes abaixo, terá que instalar usando o comando `install.packages("nome do pacote")`.

```
library(ggplot2)
library(dplyr)
library(gapminder)

base <- gapminder %>%
  filter(year == 2007)

glimpse(base)
```

```
## Rows: 142
## Columns: 6
## $ country   <fct> "Afghanistan", "Albania", "Algeria", "Angola", "Argentina", ~
## $ continent <fct> Asia, Europe, Africa, Africa, Americas, Oceania, Europe, Asi~
## $ year      <int> 2007, 2007, 2007, 2007, 2007, 2007, 2007, 2007, 2007, 2007, ~
## $ lifeExp   <dbl> 43.828, 76.423, 72.301, 42.731, 75.320, 81.235, 79.829, 75.6~
## $ pop       <int> 31889923, 3600523, 33333216, 12420476, 40301927, 20434176, 8~
## $ gdpPercap <dbl> 974.5803, 5937.0295, 6223.3675, 4797.2313, 12779.3796, 34435~
```

GGPlot2 - a base de tudo

O R por si só possui funções para gerar gráficos, porém o ggplot2 é um pacote que fornece um conjunto bem extenso de possibilidades

```
hist(base$lifeExp)
```

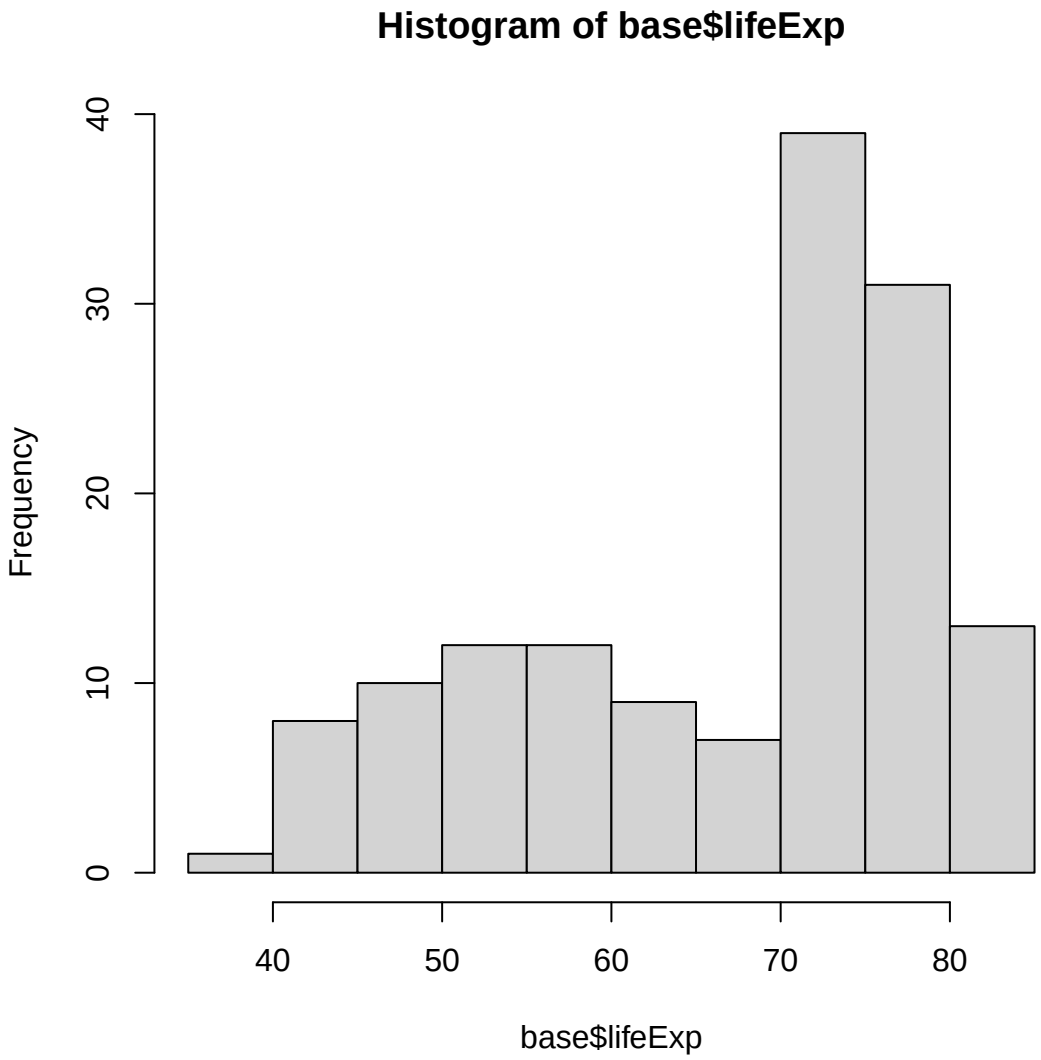

Vamos criar um histograma sobre a variável expectativa de vida.

```
ggplot(base, aes(x = lifeExp)) + geom_histogram()
```

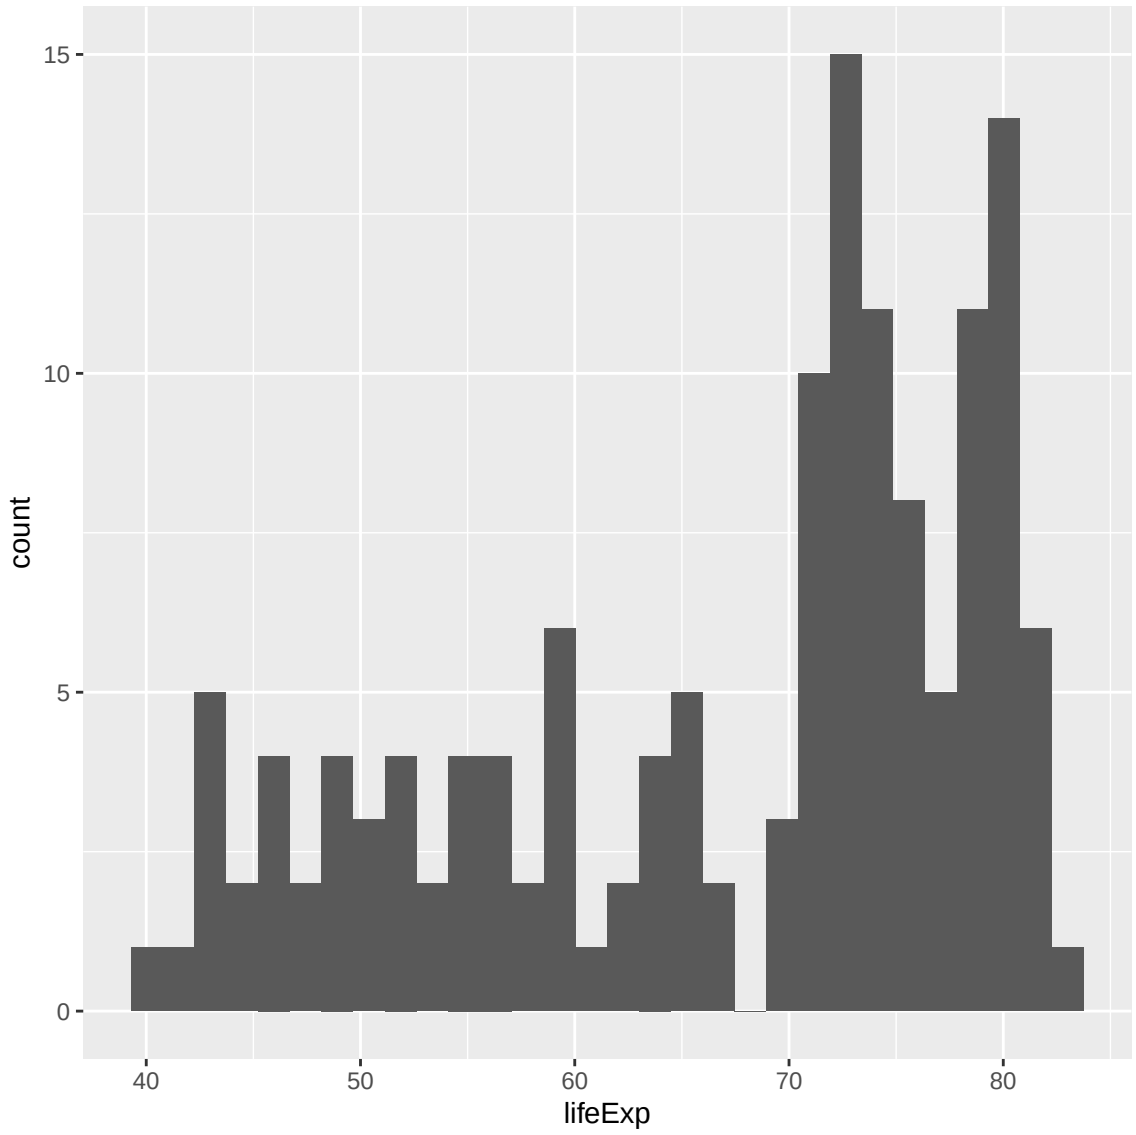

Densidade

Vamos criar um gráfico de densidade sobre a variável expectativa de vida. Veja outra forma de usar a função ggplot.

```
base %>%
  ggplot(aes(x = lifeExp)) + geom_density()
```

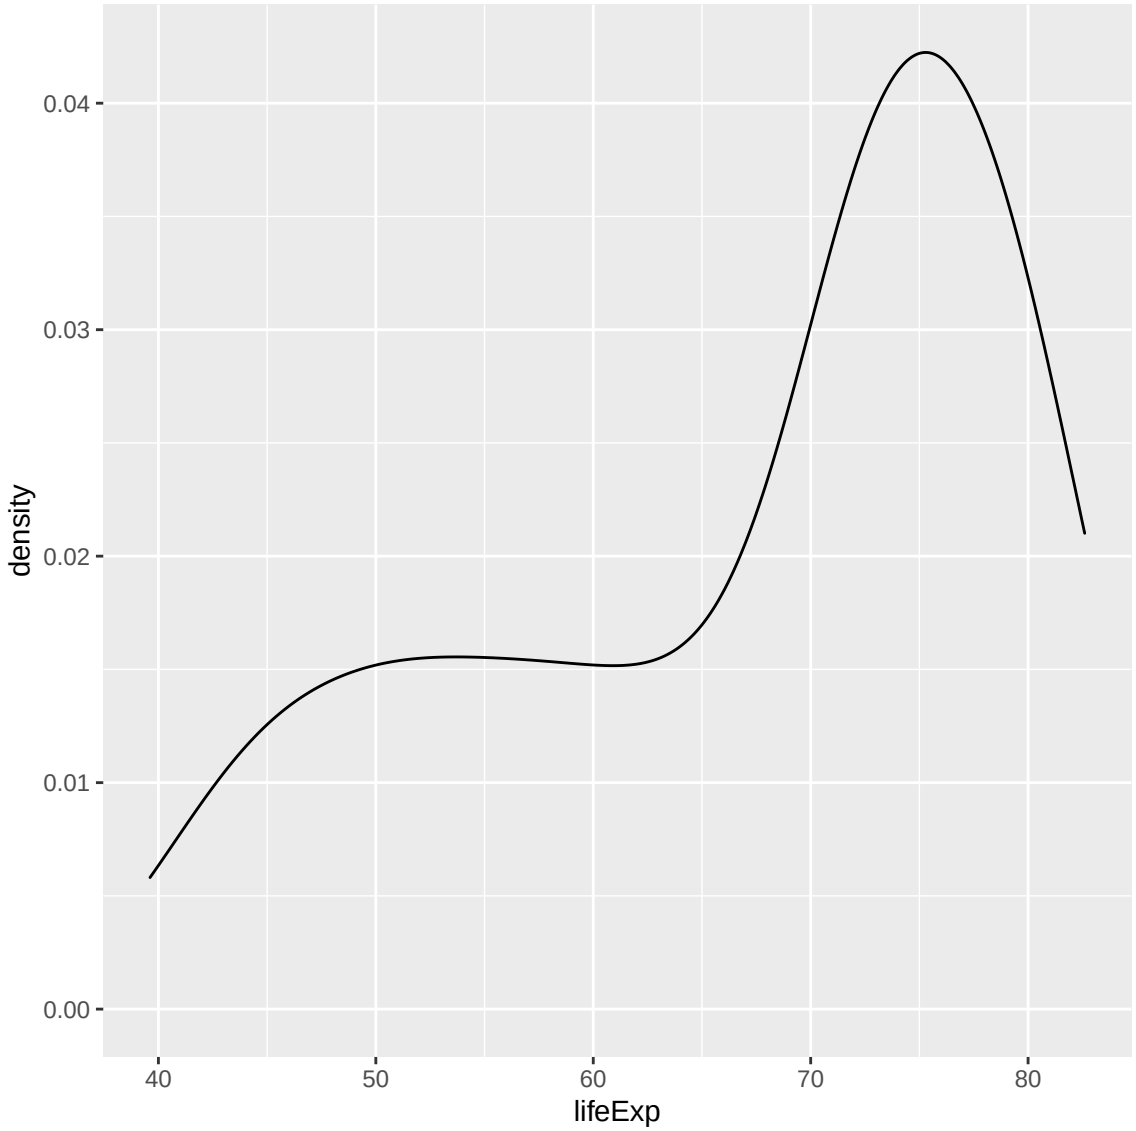

Boxplot

Vamos criar um boxplot sobre a variável expectativa de vida.

```
base %>%
  ggplot(aes(y = lifeExp)) + geom_boxplot()
```

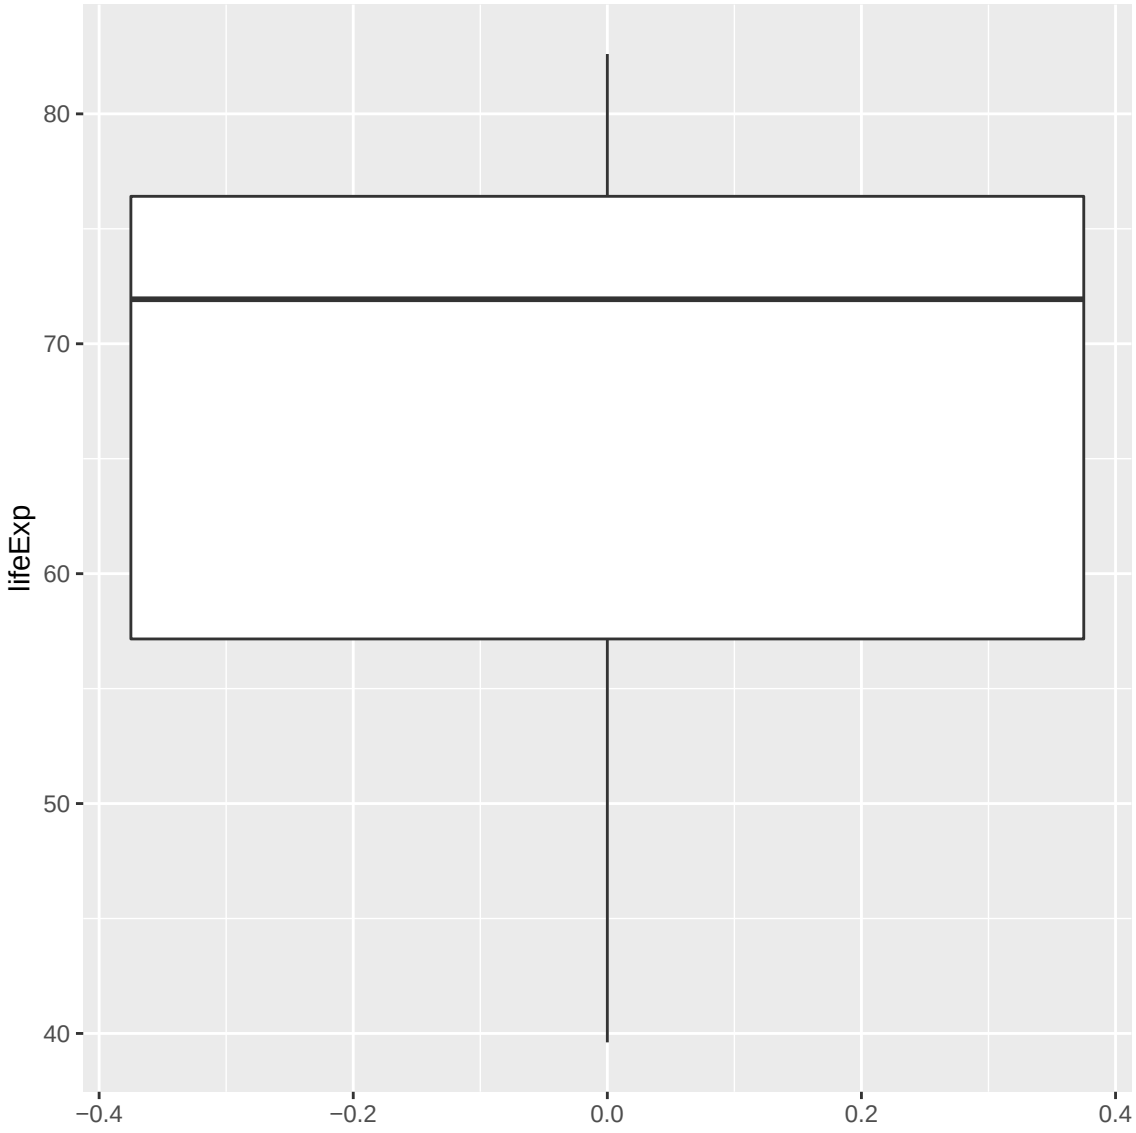

Vamos criar outro boxplot sobre a variável expectativa de vida.

```
base %>%
  ggplot(aes(x = continent, y = lifeExp)) + geom_boxplot()
```

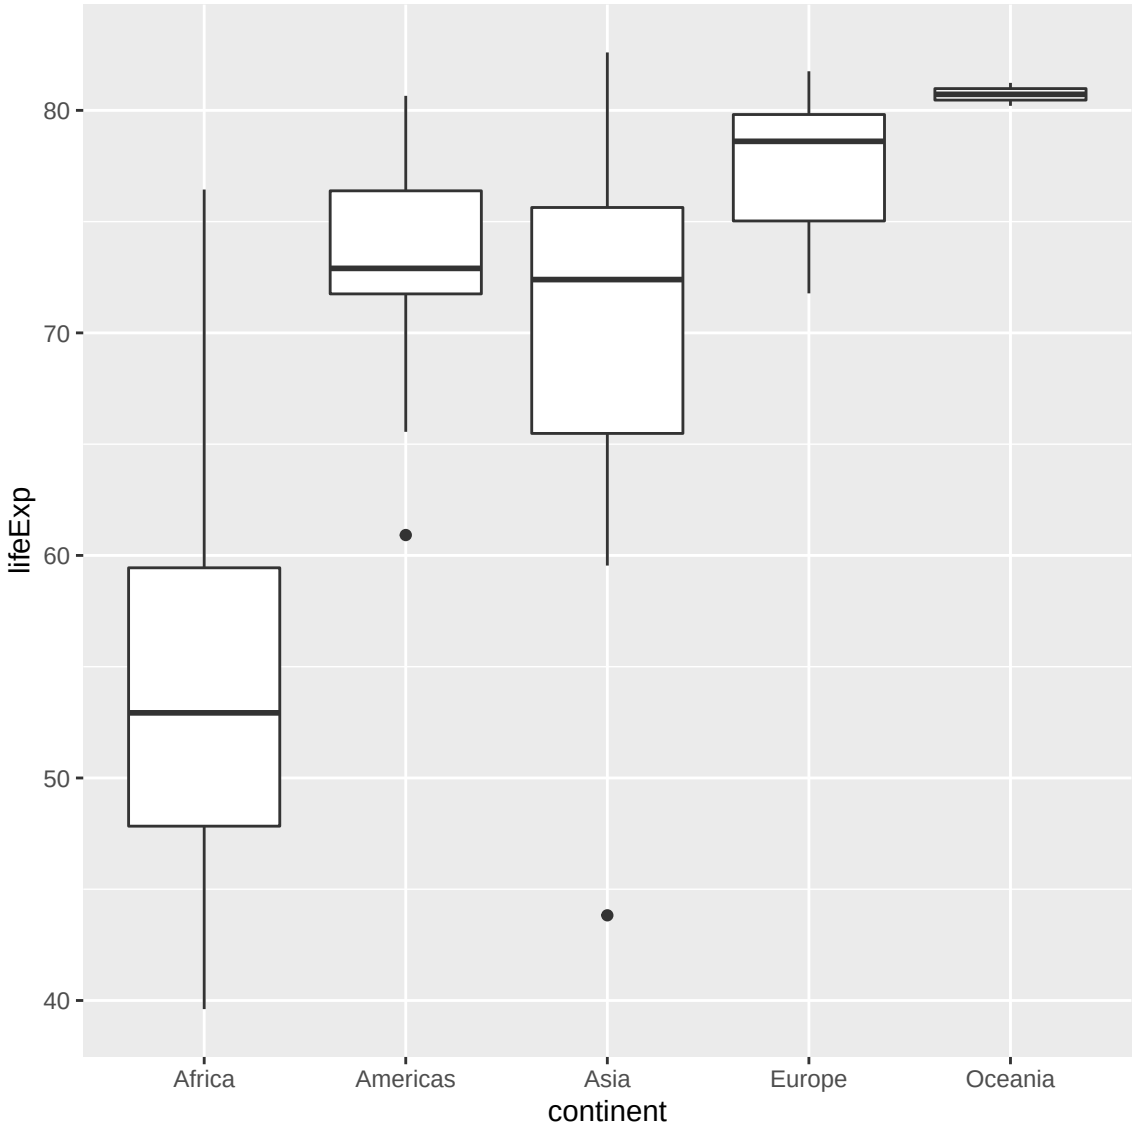

Gráfico de colunas

Vamos criar um gráfico de barras da variável expectativa de vida. Nesse caso, vamos manter os 10 países da Ásia com maior taxa de expectativa de vida.

```
base %>%
  filter(continent == "Asia") %>%
  top_n(n = 10, wt = lifeExp) %>%
  ggplot(aes(x = country, y = lifeExp)) + geom_col()
```

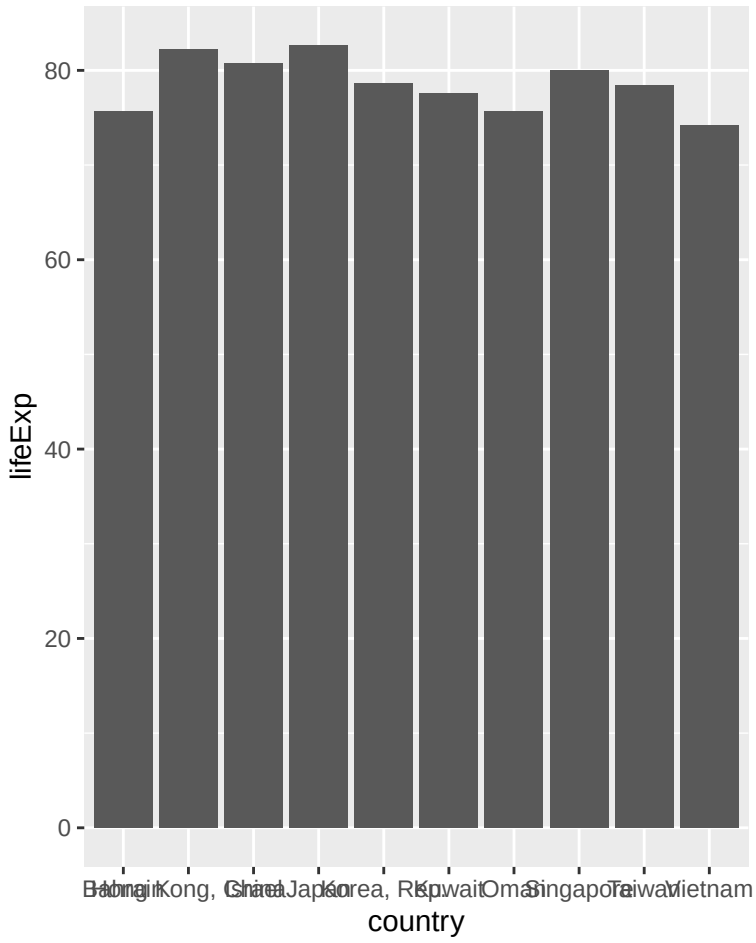

Coord_flip

Veja como melhorar a visualização com um simples argumento:

```
base %>%
  filter(continent == "Asia") %>%
  top_n(n = 10, wt = lifeExp) %>%
  ggplot(aes(x = country, y = lifeExp)) + geom_col() + coord_flip()
```

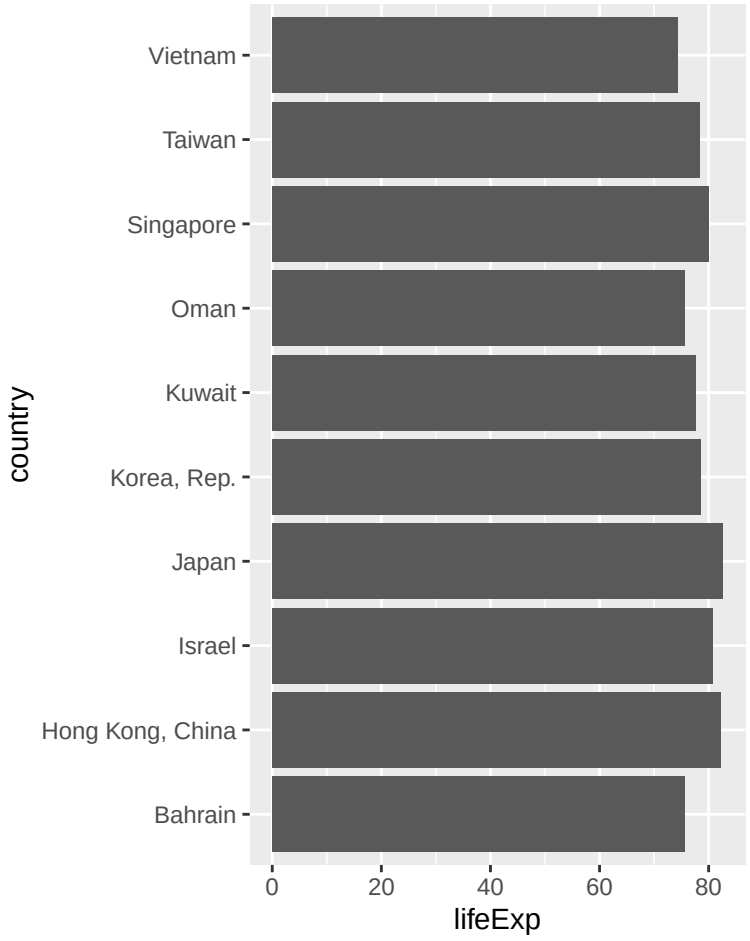

Mas consigo deixar em ordem?

Sim, para isso, vamos usar uma função do pacote forcats.

```
library(forcats)
base %>%
  filter(continent == "Asia") %>%
  top_n(n = 10, wt = lifeExp) %>%
  ggplot(aes(x = fct_reorder(country,lifeExp), y = lifeExp)) + geom_col() + coord_flip()
```

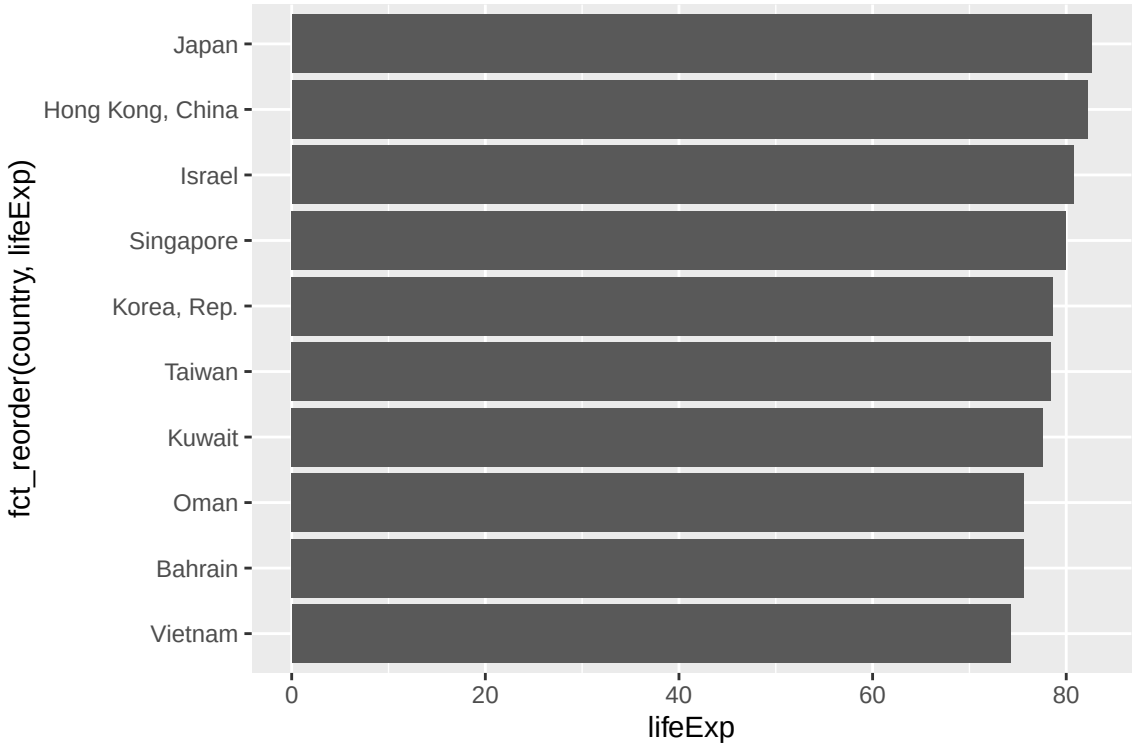

Labels

Adicionando labels

```
base %>%
  filter(continent == "Asia") %>%
  top_n(n = 10, wt = lifeExp) %>%
  ggplot(aes(x = fct_reorder(country,lifeExp), y = lifeExp)) + geom_col() +
  geom_label(aes(label=round(lifeExp))) +  coord_flip()
```

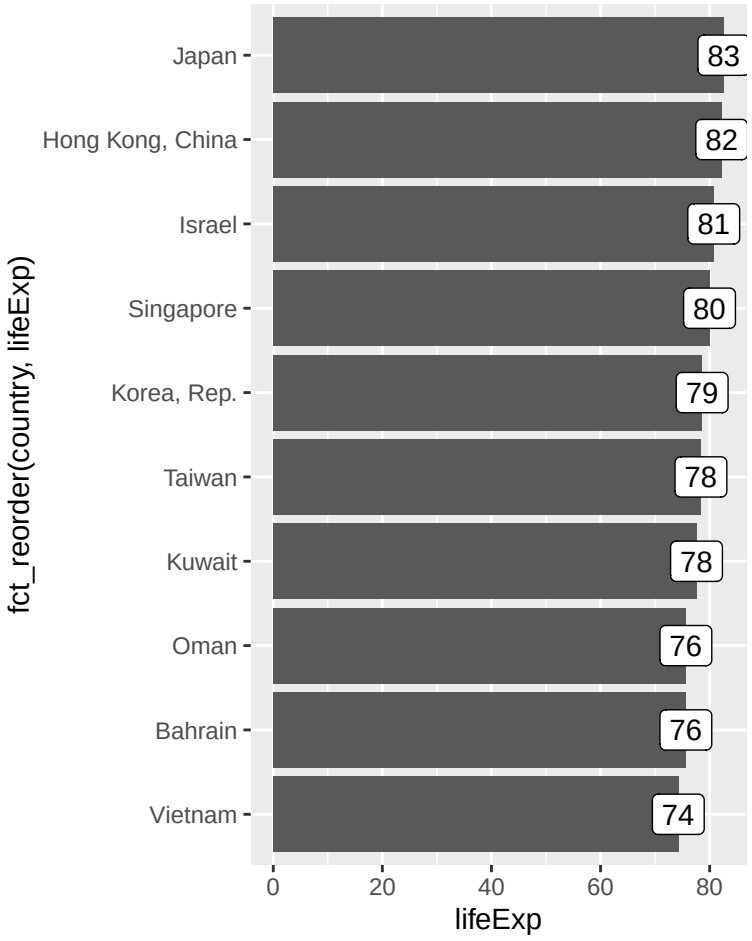

Linhas

Para fazer esse gráfico, vamos usar a base original, gapminder, e filtrar apenas o Brasil.

```
gapminder %>%
  filter(country == "Brazil") %>%
  ggplot(aes(x = year, y = lifeExp)) + geom_line()
```

Argumento col

Veja que legal é o argumento col dentro do `aes`! Nesse caso pegamos Brasil e Argentina. Olha como estamos filtrando... Primeiro criamos um vetor com o nome dos países e depois aplicamos o filter usando o `%in`.

```
paises <- c("Brazil","Argentina")
gapminder %>%
  filter(country %in% paises) %>%
  ggplot(aes(x = year, y = lifeExp, col = country)) + geom_line()
```

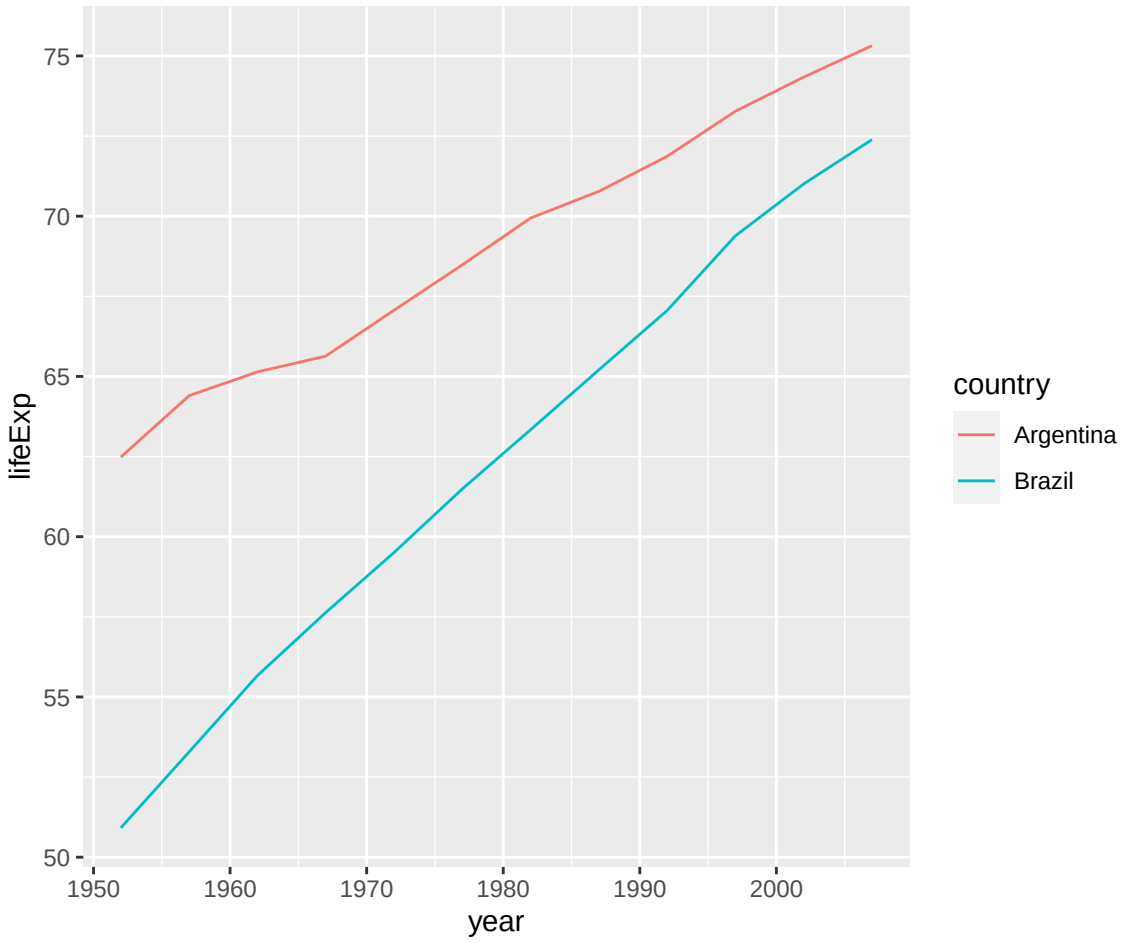

Usando argumento fill

Vamos ver como funciona o argumento `fill`.

```
base %>%
  top_n(10) %>%
  ggplot(aes(x = fct_reorder(country,gdpPercap), y=gdpPercap, fill = continent)) + geom_col() + coord_fl
```

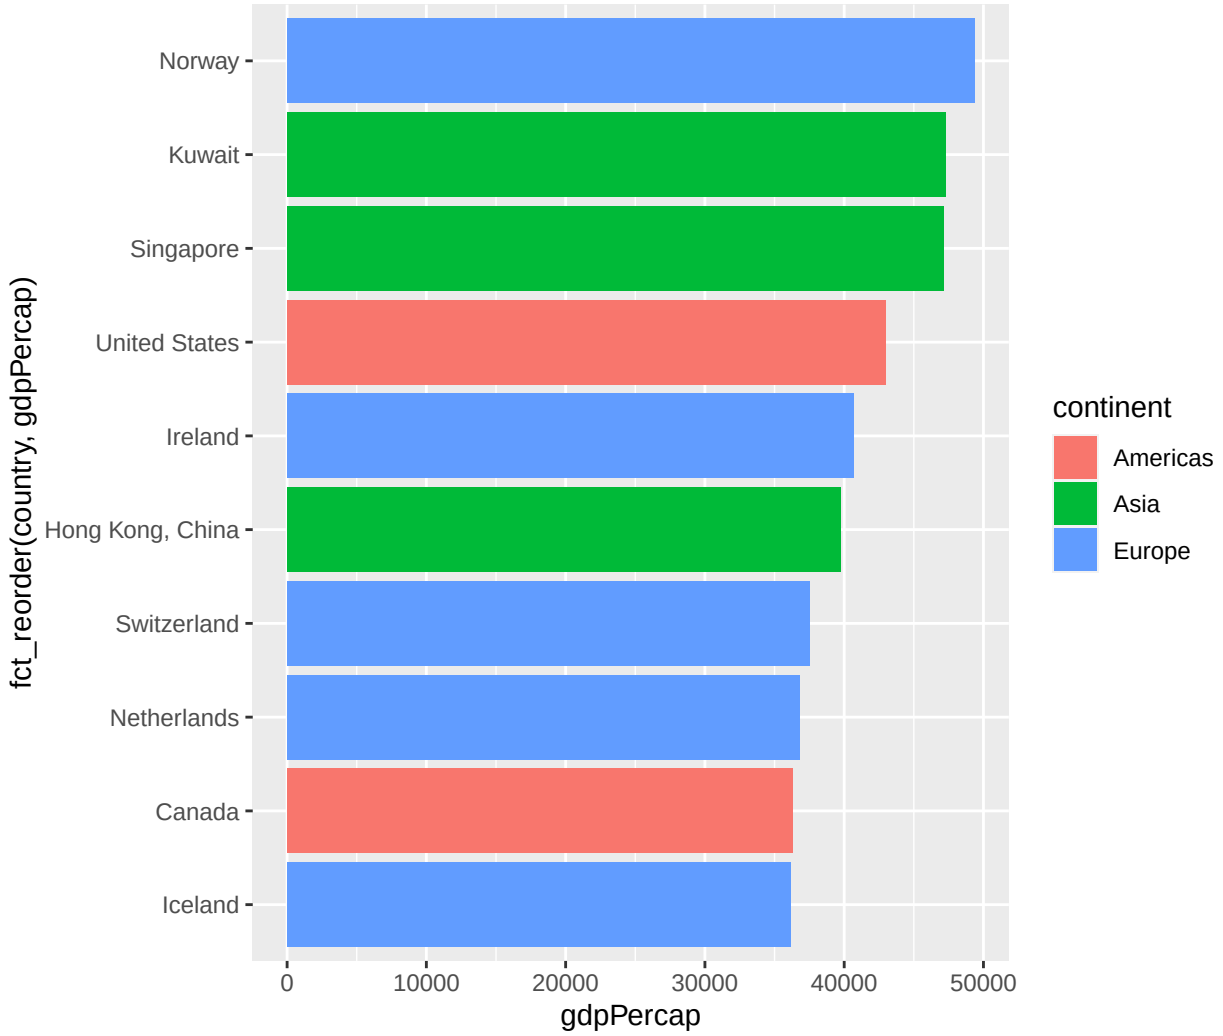

Podemos customizar mais elementos?

```
ggplot(base,aes(x=lifeExp)) + geom_density(fill="darkblue") +
  labs(title = "Histograma da expectativa de vida",
       x = "Expectativa de vida", y = "Frequência") + theme_minimal()
```

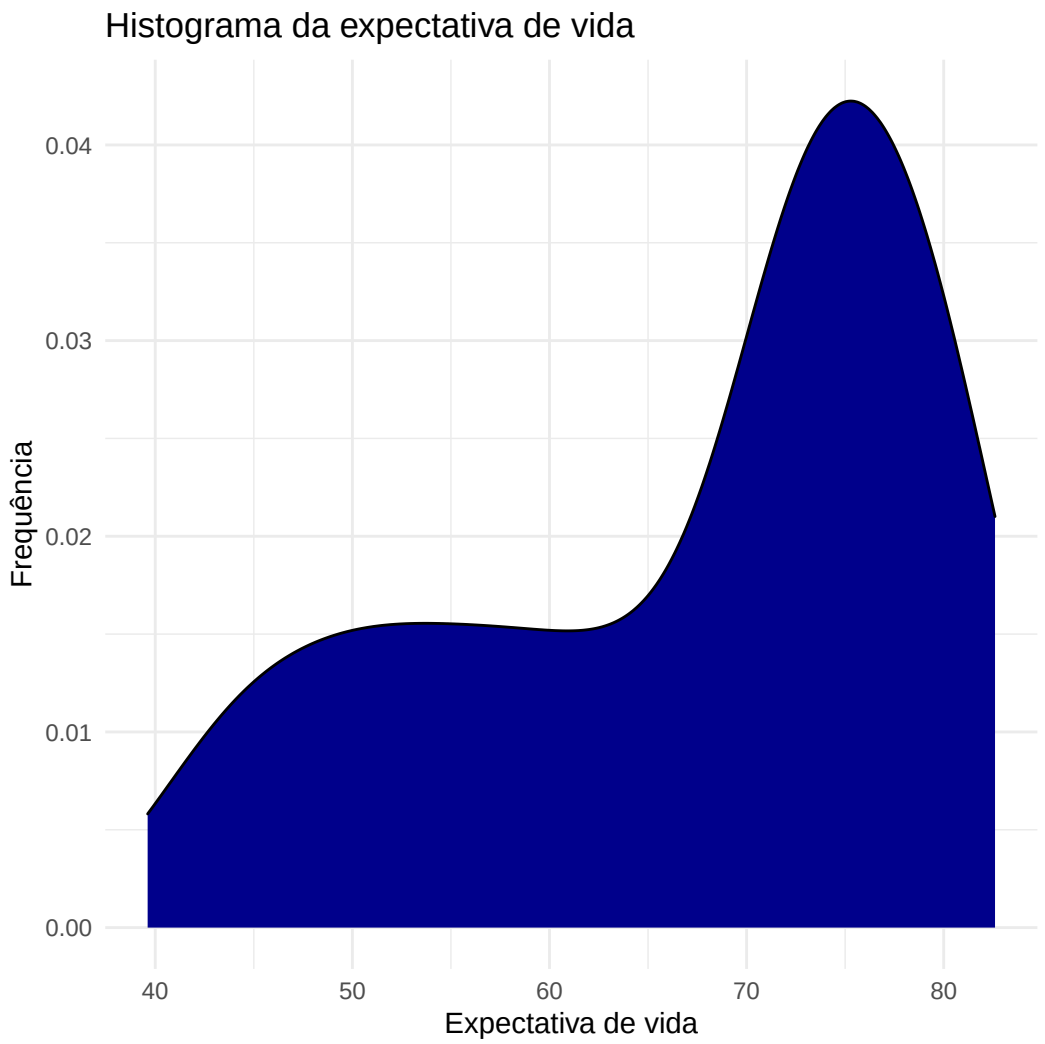

Dá para customizar uma muitos outros elementos: cores de fundo, de linhas, tamanho de letras, posição da legenda e assim por diante.

Vamos trabalhar com duas variáveis

Vamos relacionar duas variáveis: PIB per capita e expectativa de vida

```
ggplot(base,aes(x=log(gdpPercap),y=lifeExp)) + geom_point() +
  labs(x = "PIB per capita (log)", y = "Expectativa de vida") + theme_bw()
```

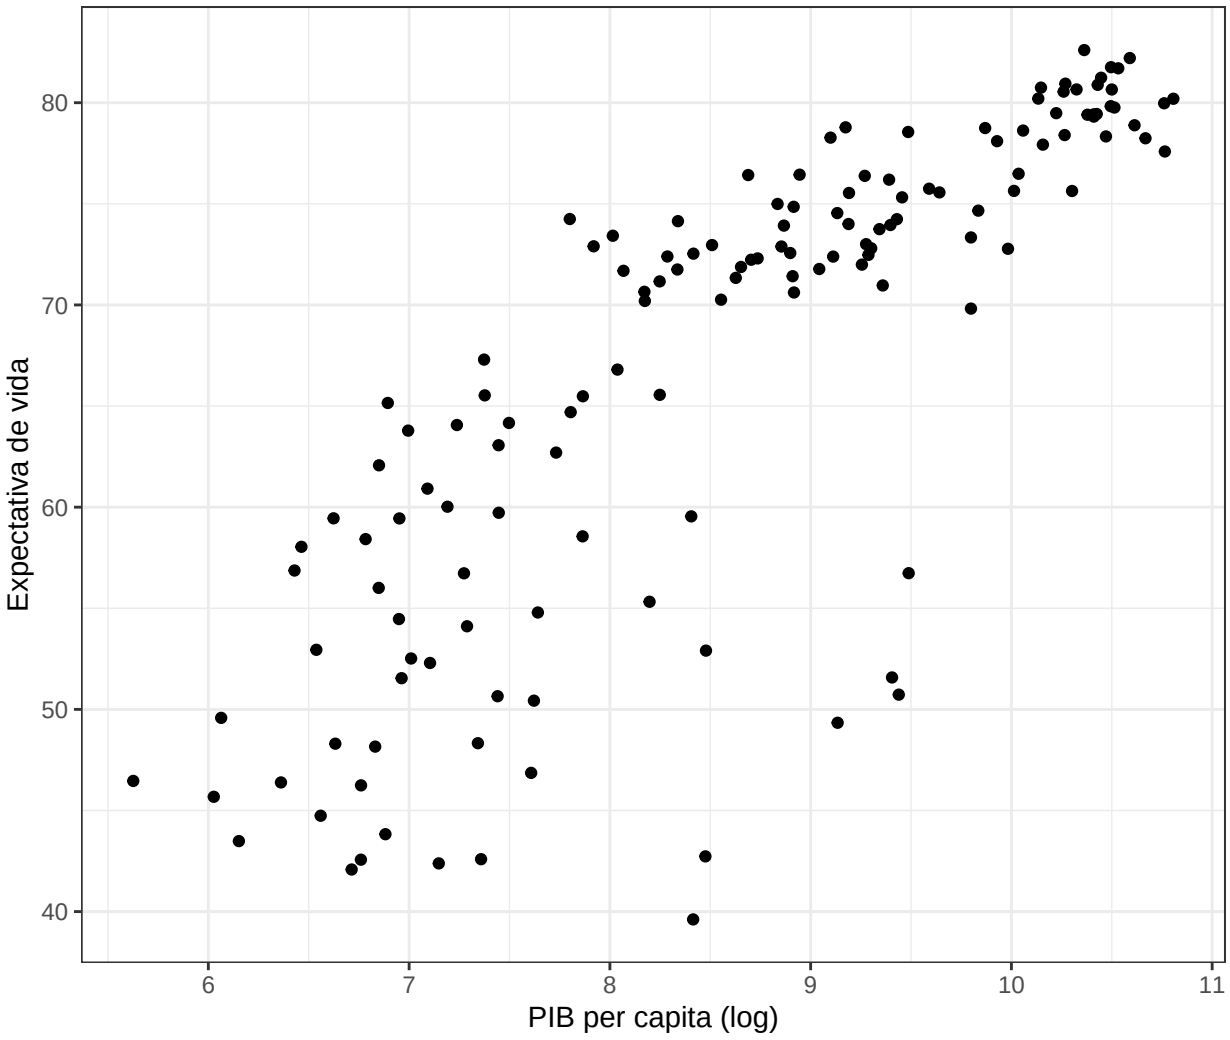

Mais uma camada

```
ggplot(base,aes(y=lifeExp, x=log(gdpPercap))) + geom_point() +
  geom_smooth(method = "lm", se=FALSE) +
  labs(x = "PIB per capita (log)",
       y = "Expectativa de vida") + theme_bw()
```

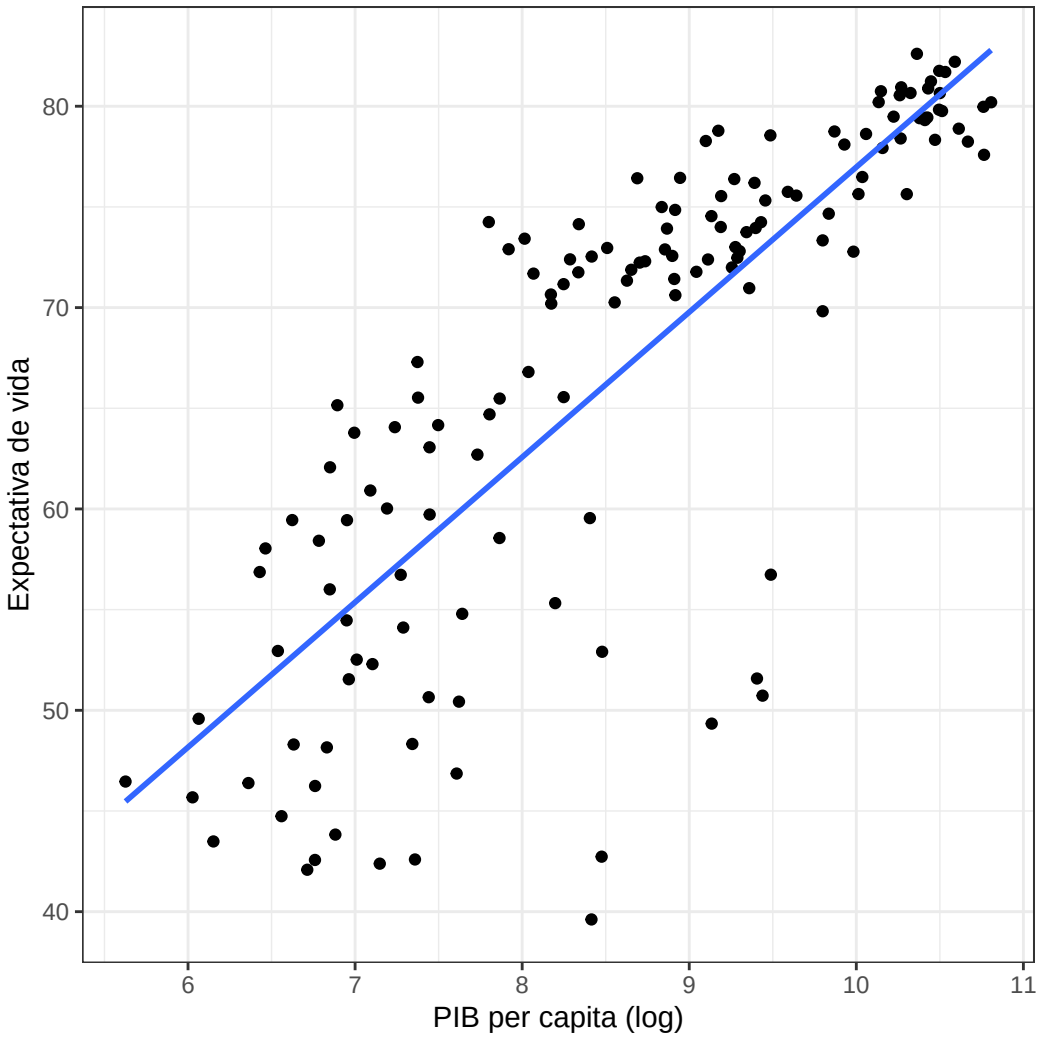

Argumento col

```
ggplot(base,aes(y=lifeExp, x=log(gdpPercap), col=continent)) + geom_point() +
  geom_smooth(method = "lm", se=FALSE) +
  labs(x = "PIB per capita (log)",
       y = "Expectativa de vida") + theme_bw()
```

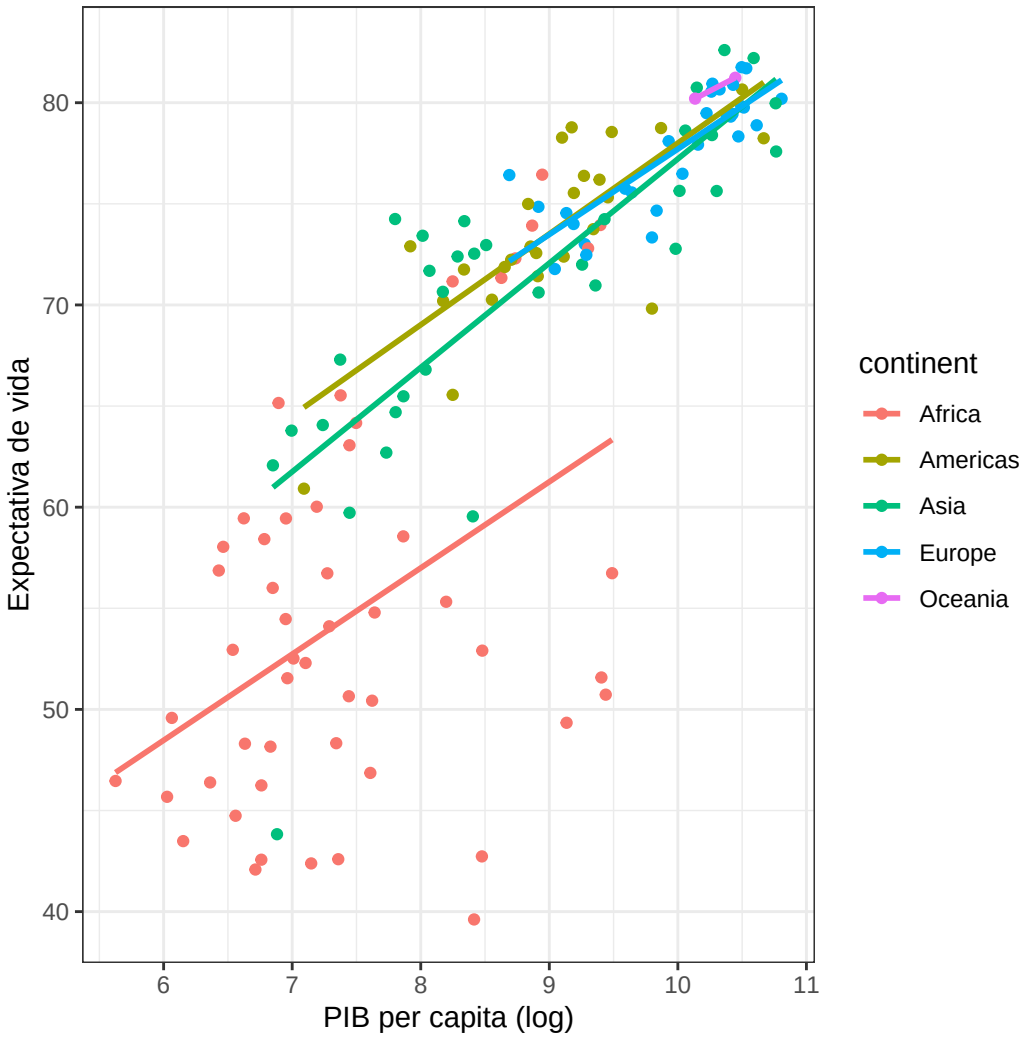

Argumento size

```
ggplot(base,aes(y=lifeExp, x=log(gdpPercap), col=continent,size = pop)) + geom_point() +
  geom_smooth(method = "lm", se=FALSE) +
  labs(x = "PIB per capta (log)",
       y = "Expectativa de vida") + theme_bw()
```

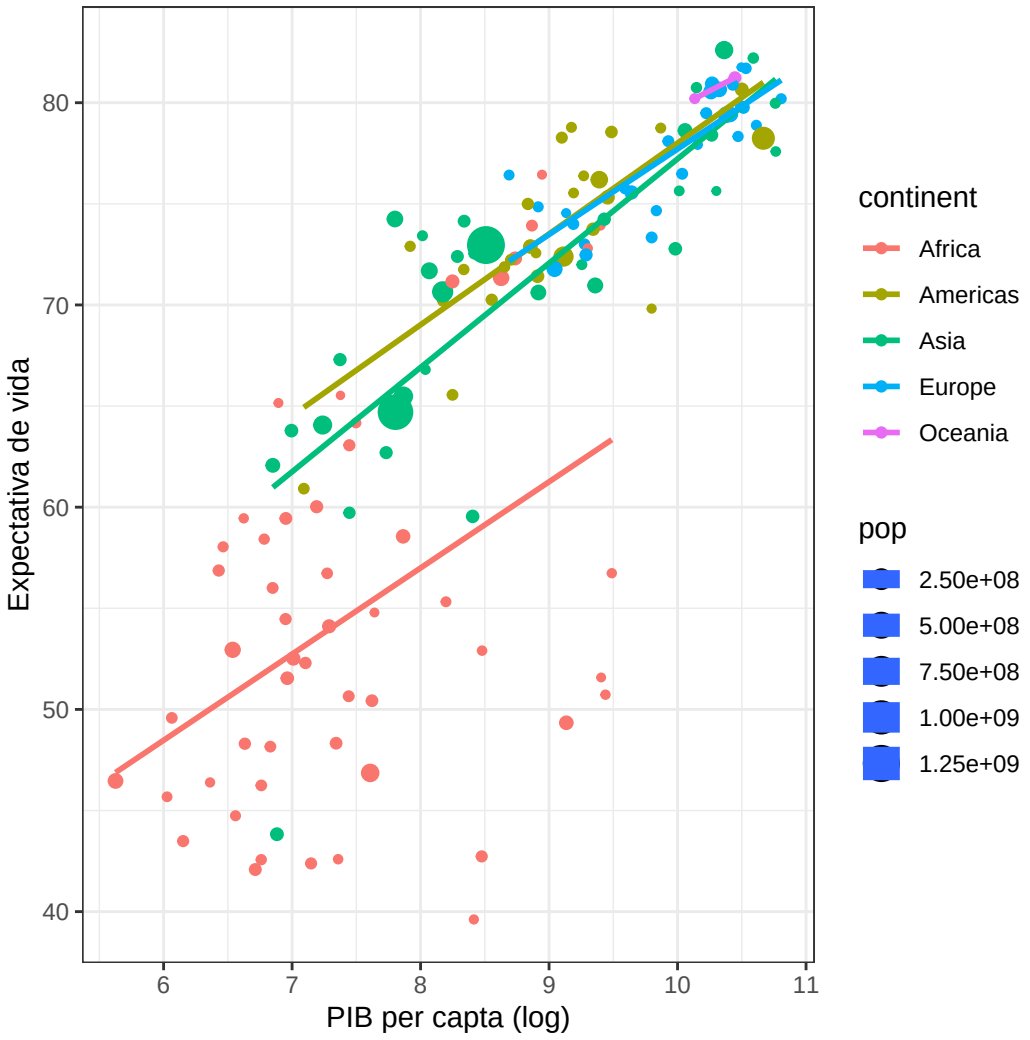

Facet

```
ggplot(base,aes(x=log(gdpPercap), y=lifeExp, col=continent,
                size = pop)) + geom_point() + geom_smooth(method = "lm", se=FALSE) +
  labs(x = "PIB per capita (log)", y = "Expectativa de vida") + theme_bw() +
  facet_grid(~continent)
```

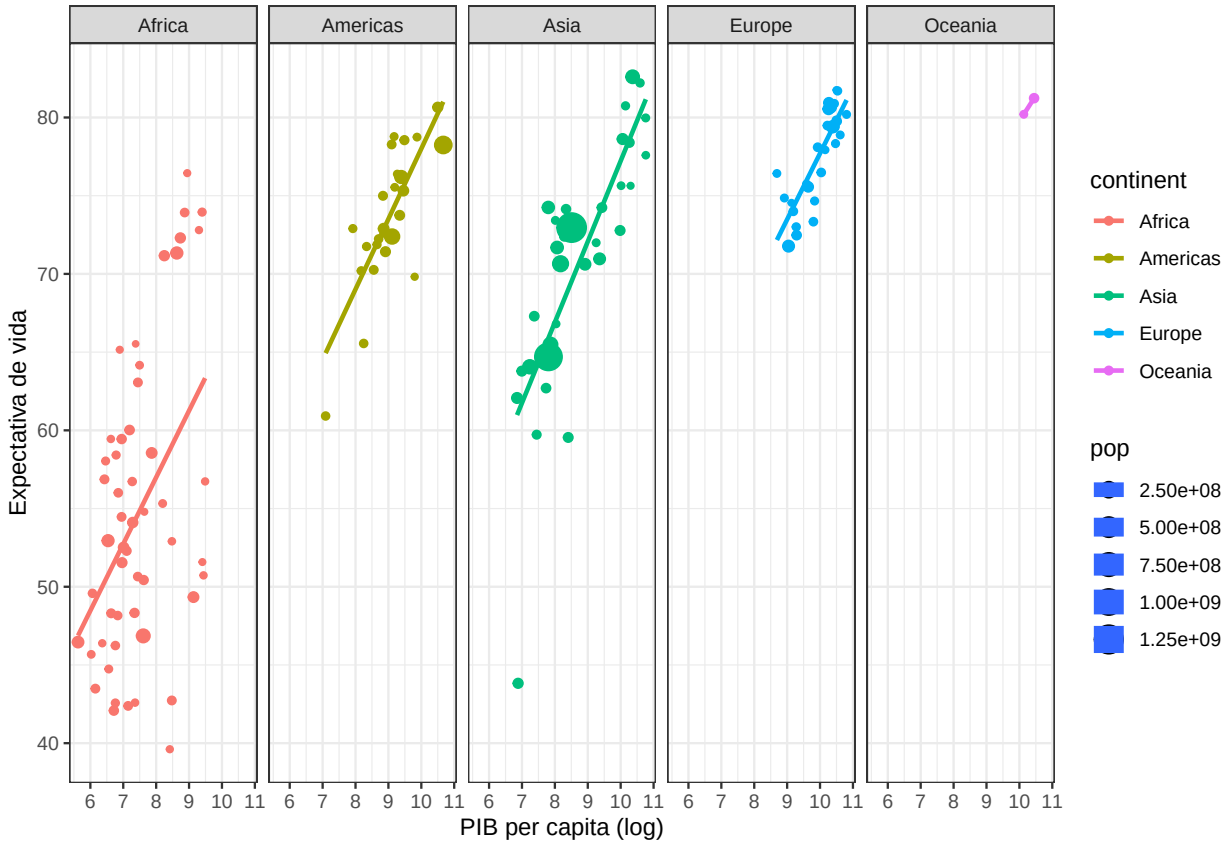

Criando gráficos com Esquisse

O esquisse permite visualizar gráficos no estilo ggplot2 usando point n' click. É uma ótima ferramenta para "estudar" o ggplot2.

```
library(esquisse)

esquisser(viewer = "browser")
```

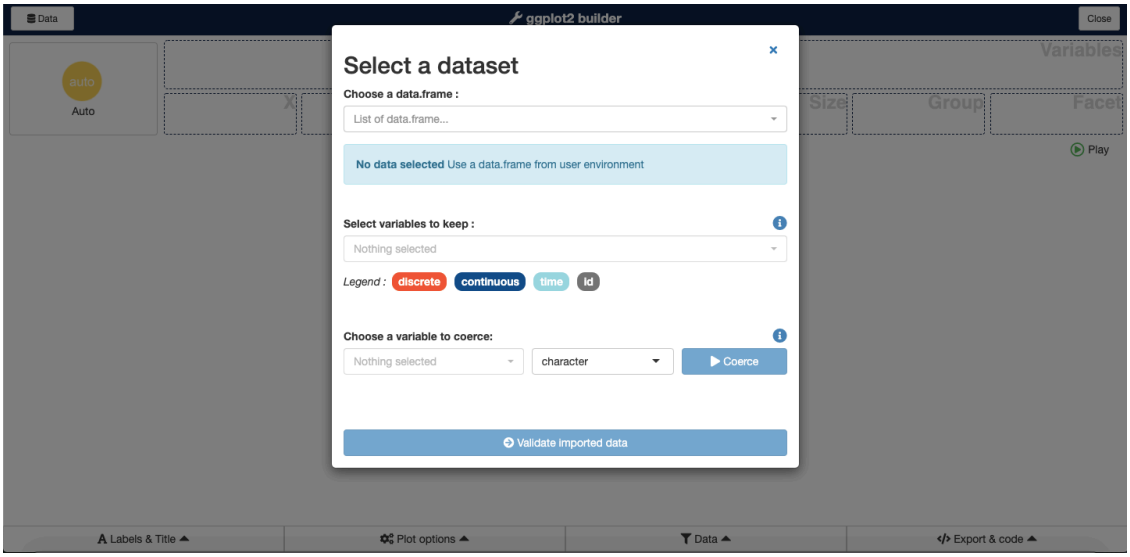

Gerando gráficos interativos

Vamos resgatar um gráfico que fizemos lá atrás.

```
library(plotly)
grafico <- ggplot(base,aes(y=lifeExp, x=log(gdpPercap), col=continent)) + geom_point() +
  labs(x = "PIB per capita (log)",
       y = "Expectativa de vida") + theme_bw()
ggplotly(grafico)
```

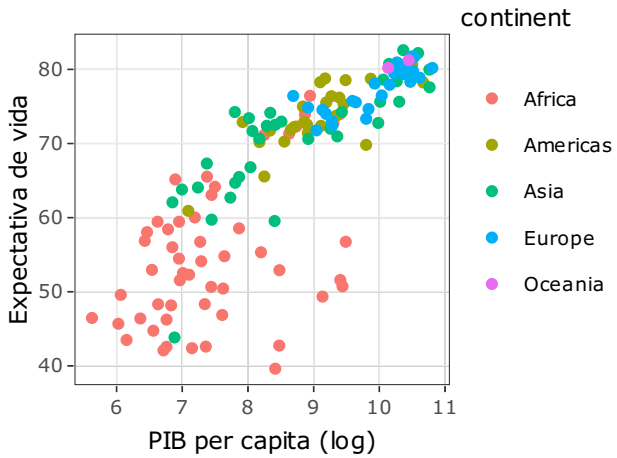

Para aprender mais

Ao clicar será direcionad@ para a página indicada

- GGPlot2 cheat sheet
- GGPlot2 - LAPEI
- Plotly
- Blog Datanovia
- Datavis with R
- Live Curso-R sobre extensões do ggplot2
- The R graph gallery
- Documentação dplyr
- Documentação ggplot2

Obrigado

Se encontrou algum erro ou tem alguma sugestão de melhoria pode entrar em contato. Se foi útil também avise! Ah... e pode passar adiante. Quanto mais gente tendo acesso a esse conhecimento melhor!

Daniel Pagotto | danielppagotto@gmail.com | LinkedIn

LAPEI - UFG | lapeiufg@gmail.com. | No instagram: lapeiufg